

# Processus stochastiques: cryptanalyse

Stegen Thomas s154315  
Adrien Minne s154340  
Delaunoy Arnaud s153059

# 1 Première partie : chaines de Markov pour la modélisation du langage et MCMC

## 1.1 Chaîne de Markov pour la modélisation du langage

### Question 1

L'élément  $(i,j)$  de la matrice de transition correspond à la probabilité de passer de l'état  $i$  à l'état  $j$ . Il correspond donc à la probabilité que la lettre  $i$  soit suivie de la lettre  $j$  dans la séquence. Dès lors, soit  $\theta$  l'élément  $(i,j)$  de la matrice de transition,  $\theta$  est le paramètre d'une loi de Bernouilli avec comme possibilités :

- l'élément  $i$  est suivi de  $j$  (avec une probabilité  $\theta$ )
- l'élément  $i$  n'est pas suivi de  $j$  (avec une probabilité  $1 - \theta$ )

La méthode du maximum de vraisemblance consiste à maximiser  $P(\mathbf{D}_n|\theta)$  avec  $\mathbf{D}_n$  l'échantillon de donnée, ici seq1 et  $n$  le nombre de données. Pour une variable de Bernouilli, on a : Soit,

$$x_i = \begin{cases} 1 & \text{si } i \text{ est suivi de } j \\ 0 & \text{si } i \text{ n'est pas suivi de } j \end{cases}$$

et  $m$  le nombre d'occurrences de la lettre  $i$ .

$$\begin{aligned} P(\mathbf{D}_n|\theta) &= \prod_{i=1}^m (x_i\theta + (1 - x_i)(1 - \theta)) \\ &= \theta^{n_1}(1 - \theta)^{n_0} \end{aligned}$$

Avec  $n_0$  le nombre de fois où  $x_i = 0$  et  $n_1$  le nombre de fois où  $x_i = 1$ . Déterminons maintenant le  $\theta$  maximisant cette fonction :

$$\begin{aligned} \frac{\partial P(\mathbf{D}_n|\theta)}{\partial \theta} &= n_1\theta^{n_1-1}(1 - \theta)^{n_0} - n_1\theta^{n_1}(1 - \theta)^{n_0-1} \\ &= \theta^{n_1-1}(1 - \theta)^{n_0-1}(n_1(1 - \theta) - n_0\theta) \\ &= \theta^{n_1-1}(1 - \theta)^{n_0-1}(n_1 - \theta(n_1 + n_0)) \end{aligned}$$

La valeur de  $\theta$  maximisant la fonction  $P(\mathbf{D}_n|\theta)$  est donc :

$$\theta_{i,j} = \frac{n_1}{n_0 + n_1} = \frac{\text{nombre d'occurrences de } i \text{ suivies de } j}{\text{nombre d'occurrences de } i}$$

### Question 2

### Question 3

### Question 4

### Question 5

## 1.2 Algorithme MCMC

### Question 1

Pour prouver que  $\pi_0$  est une distribution stationnaire de la chaîne de Markov, il suffit de prouver que  $\pi_0 = \pi_0 * Q$ . On sait que les équations de balances détaillées  $\pi_0(i)Q_{i,j} = \pi_0(j)Q_{j,i}$

sont satisfaites. Passant en notation indicelle, on doit donc montrer que :

$$\begin{aligned}
 \pi_0(i) &= \sum_{k=0}^N \pi_0(k) * Q_{k,i} \\
 &= \sum_{k=0}^N \pi_0(i) * Q_{i,k} \\
 &= \pi_0(i) \sum_{k=0}^N Q_{i,k} \\
 &= \pi_0(i)
 \end{aligned}$$

Cette distribution stationnaire est unique si la matrice de transition  $Q$  est irréductible.

## Question 2

Cette démonstration a été faite avec l'aide du pdf nommé MetropolisExplanation mis dans l'archive trouvé sur internet.

Étudions d'abord la probabilité de transition.

La probabilité d'obtenir un élément  $x_j$  sachant que l'élément précédent de la chaîne de Markov est  $x_i$  est pour  $i \neq j$  la probabilité que cet élément soit généré selon la loi  $q$  et accepté.

$$P(x_j|x_i) = \alpha(x_j, x_i)q(x_j|x_i)$$

avec

$$\begin{aligned}
 \alpha(x_j, x_i) &= \min \left\{ 1, \frac{f(x_j) q(x_i|x_j)}{f(x_i) q(x_j|x_i)} \right\} \\
 &= \min \left\{ 1, \frac{cP_X(x_j) q(x_i|x_j)}{cP_X(x_i) q(x_j|x_i)} \right\}
 \end{aligned}$$

La probabilité d'obtenir à nouveau l'élément  $x_i$  sachant que l'élément précédent de la chaîne de Markov est également  $x_i$  est la somme de la probabilité que l'élément  $x_i$  soit généré selon la loi  $q$  et accepté et de la probabilité que tout autre élément soit généré et refusé.

$$P(x_i|x_i) = \alpha(x_i, x_i)q(x_i|x_i) + \sum_k (1 - \alpha(x_k, x_i))q(x_k|x_i)$$

Dans le cas où l'élément généré est différent du précédent, on a :

$$\begin{aligned}
 P(x_j|x_i)\pi_0(x_i) &= \alpha(x_j, x_i)q(x_j|x_i)\pi_0(x_i) \\
 &= \min \left\{ 1, \frac{cP_X(x_j)}{cP_X(x_i)} \frac{q(x_i|x_j)}{q(x_j|x_i)} \right\} q(x_j|x_i)\pi_0(x_i) \\
 &= \frac{\pi_0(x_i)}{cP_X(x_i)} \min \{ cP_X(x_i)q(x_j|x_i), cP_X(x_j)q(x_i|x_j) \} \\
 &\text{en posant } x_i \leftarrow x_j \text{ et } x_j \leftarrow x_i \\
 &= \frac{\pi_0(x_j)}{cP_X(x_j)} \min \{ cP_X(x_j)q(x_i|x_j), cP_X(x_i)q(x_j|x_i) \} \\
 &= \min \left\{ 1, \frac{cP_X(x_i)}{cP_X(x_j)} \frac{q(x_j|x_i)}{q(x_i|x_j)} \right\} q(x_i|x_j)\pi_0(x_j) \\
 &= \alpha(x_i, x_j)q(x_i|x_j)\pi_0(x_j) \\
 &= P(x_i|x_j)\pi_0(x_j)
 \end{aligned}$$

Dans le cas où l'élément généré est le même que le précédent,  $x_i$  étant égal à  $x_j$  il est évident que

$$P(x_i|x_j)\pi_0(x_j) = P(x_j|x_i)\pi_0(x_i)$$

car

$$P(x_i|x_i)\pi_0(x_i) = P(x_i|x_i)\pi_0(x_i)$$

## 2 Deuxième partie : décryptage d'une séquence codée

**Question 1**

**Question 2**

**Question 3**

**Question 4**

**Question 5**